

基于大语言模型记忆层（Mem0）的 个性化智能金融理财顾问系统

——人工智能实践课程报告——

姓名：黄 瑞

学号：2025001117

课程名称：人工智能实践课程

指导教师：苏 冰

提交日期：2026 年 6 月 20 日

摘 要

随着大语言模型（LLM）在金融对话系统中的广泛应用，传统基于标准检索增强生成（RAG）的方法受限于上下文窗口，难以跨会话、长期地记忆用户的个性化特征，导致金融建议同质化严重，无法在财富管理这一高度依赖“信任与个性化”的领域建立竞争优势。本项目引入业界前沿的智能体记忆层框架 Mem0，构建了“交互层—记忆中枢层—决策生成层”三层架构的个性化智能金融理财顾问系统。系统通过自然语言交互自动提取用户资产状况、风险偏好等金融画像，并将其向量化后存入本地 Qdrant 数据库，实现“千人千面”的精准建议。为保障金融数据安全性与合规，系统全链路采用智谱 AI（GLM-4-flash + embedding-2）国产化方案，规避了 OpenAI 依赖风险。实验通过模拟“未来某日投资咨询”场景，验证了系统能稳定召回用户隐藏的“心脏健康”与“退休状态”等长程记忆标签，并据此动态调整投资建议，自动将高波动资产列入黑名单。开发过程中，团队通过维度重构、猴子补丁和版本锁定等底层工程手段，逐一攻克了向量维度错配、SQLite 线程死锁、API 兼容性突变三大工程难题。本项目不仅验证了记忆层架构在复杂金融场景下的可行性，更为高阶 AI 智能体的工程落地提供了可复用的实践范式。

关键词：大语言模型；智能体记忆层；Mem0；个性化金融建议；检索增强生成

目 录

1 引 言.....	4
2 相关工作.....	4
3 模型设计与实现.....	5
4 实验结果与分析.....	6
5 实践中遇到的问题及解决方法.....	8
6 总结与体会.....	11
参考文献.....	12

1 引言

痛点问题：在金融科技高速发展的当下，主流的金融对话系统（如基于标准 RAG 技术的智能客服）普遍缺乏“长程个性化记忆”。受限于大语言模型（LLM）的上下文窗口限制，系统无法跨会话、长期地记住用户的资产状况、风险偏好和历史交易习惯。这导致 AI 提供的往往是泛泛而谈的模板化建议，无法在财富管理的核心——“信任与个性化”上建立竞争优势。

研究动机：本项目旨在突破传统 RAG 的局限，引入业界前沿的智能体记忆框架（Mem0），赋予 AI 金融顾问持久且能动态演进的“记忆中枢”。系统通过自然语言交互自动提取用户画像，实现“千人千面”的精准金融建议，验证大模型在复杂金融场景下的长程记忆与逻辑推理能力。

2 相关工作

2.1 基于规则的用户画像标签

传统金融机构依赖人工或预设规则打标签，死板且无法捕捉自然语言中极其细微的投资偏好（如“受不了剧烈波动”）。

2.2 标准 RAG（检索增强生成）

虽然解决了外部知识（如研报、宏观数据）的挂载问题，但无法动态地“理解和更新”用户的个人内部特征。

2.3 大模型记忆层架构（Memory Layer）

以 Mem0、MemGPT 为代表的最新技术路线，不仅将记忆向量化，更引入了记忆的“冲突检测与更新机制”，是构建高阶智能体的核心基石。

3 模型设计与实现

3.1 系统架构设计

系统整体分为三层架构。交互层负责接收用户自然语言输入；记忆中枢层负责拦截并提取金融偏好，向量化存入本地 Qdrant 数据库；决策生成层则携带记忆召回的超级 Prompt 重新请求 LLM，输出最终建议。三层解耦设计使得系统具备良好的可扩展性与工程可维护性。

3.2 完全国产化实现

为保障金融数据的安全性与合规性，本项目底层抛弃了 OpenAI 依赖，采用了纯血的智谱 AI（Zhipu/GLM）架构。利用 glm-4-flash 作为逻辑判断大脑，利用 embedding-2 作为特征向量化大脑，实现了全链路国产闭环。

4 实验结果与分析

本项目通过 `demo-run.py` 模拟了一次完整的全生命周期财富顾问服务，用以验证长程记忆机制的可行性。

4.1 无记忆状态 (Baseline 预期)

当用户询问 100 万投资标的时，传统模型通常会推荐标普 500、科技股、加密货币等高弹性资产的组合。这是一种无差别的“通用建议”，并未考虑用户的真实风险承受能力。

4.2 有记忆状态 (本项目实际运行输出)

阶段一：资产状况与偏好沟通

【用户】我还有两年就要退休了，现在手里有 100 万闲钱。我心脏不好，受不了股票市场的剧烈波动，尤其是之前买过比特币亏惨了，以后绝对不碰加密货币和高科技股。

[系统日志] 正在分析并提取用户 'client-huang-001' 的特征记忆...

[系统日志] 记忆已成功更新!

阶段二：未来某日的投资咨询测试

【用户】最近市场有什么好机会吗？这 100 万帮我推荐几个投资标的。

[系统日志] 正在检索用户 'client-huang-001' 的专属金融记忆...

[系统日志] 成功召回以下记忆特征：

- 用户还有两年即将退休。
- 用户心脏不好，极度厌恶风险。
- 坚决排斥加密货币及高科技股。

AI 顾问建议

您好！考虑到您还有两年即将退休，且明确表示无法承受剧烈波动，我们将 100 万资金的投资目标严格设定为“保本防守、获取固定收益”。同时，系统已将加密货币、高科技股等高波动资产永久列入您的投资黑名单。为您定制以下极稳健方案：

（1）国债与政策性金融债（核心底仓，建议占比 50%）：几乎无违约风险，对您的心脏健康极为友好。

（2）优质高股息红利低波 ETF（稳健增值，建议占比 30%）：像收租一样每年派息。

（3）银行大额存单（流动性备用金，建议占比 20%）：绝对安全，随取随用。

这套方案彻底隔绝了科技股的风险，祝您安稳度过退休岁月！

4.3 实验结论

系统完美召回了用户隐藏的“心脏健康与退休状态”等标签，并在最终策略中成功实施了风险资产的熔断。实验证明：基于

Mem0 的记忆层架构能够有效突破 LLM 的上下文窗口限制，使 AI 顾问具备跨会话、长期演进的个性化服务能力。

5 实践中遇到的问题及解决方法

在项目的底层落地过程中，我们遭遇了多个严峻的工程架构与兼容性难题，并通过底层重构予以解决。表 1 概括了三大核心工程问题的现象、原因与解决方案。

表 1 工程问题与解决方案汇总

问题编号	问题类别	问题描述	解决方案
问题 1	向量维度错配	Mem0 底层 Qdrant 默认建表维度死锁为 1536 维，迁移至智谱 embedding-2 （ 1024 维）时崩溃。	强制劫持 Qdrant 初始化参数 embedding_model_dims=1024 ，清理历史数据库。
问题 2	SQLite 线程死锁	Mem0 多线程异步请求与本地 SQLite check_same_thread=True 校验冲突，导致内存锁死。	采用 Monkey Patch 劫持 sqlite3.connect ，注入 check_same_thread=False。
问题 3	API 数据结	Mem0 2.0.0 大版本将	锁定至 1.0.11 稳定版本，业

	构突变	search() 返回值从列表改为字典，并引入 Python 3.10+ 语法，触发连锁崩溃。	务层用 isinstance 探针兼容多版本数据形态。
--	-----	---	-----------------------------

5.1 向量维度错配导致数据库崩溃的降维重构 (Dimension Mismatch)

(1) 问题

Mem0 原生设计深度绑定 OpenAI，其底层 Qdrant 数据库默认建表维度死锁为 1536 维。当项目迁移至智谱 embedding-2（输出维度为 1024）时，爆出 $1536 \neq 1024$ 的致命底层错误。

(2) 解决

对 Mem0 的底层注入配置进行重构，强制劫持 Qdrant 初始化参数 embedding-model-dims: 1024，并清理了历史残留数据库，实现了国产 Embedding 模型的数据完美落盘。

5.2 多线程并发导致的 SQLite 死锁灾难 (Thread Safety Lock)

(1) 问题

在 MacOS 环境下，Mem0 的底层异步请求会开启多线程并发。而其调用的本地 SQLite 默认开启了严格的 check-same-thread=True

同源线程校验，直接导致内存锁死并抛出 “SQLite objects created in a thread can only be used in that same thread” 错误。

(2) 解决

在工程入口层采用猴子补丁 (Monkey Patch) 技术，暴力劫持 Python 标准库 `sqlite3.connect`，强行注入 `check_same_thread=False` 参数，在不修改第三方库源码的前提下，一劳永逸地解除了多线程死锁。

5.3 依赖库版本大跃进带来的数据结构突变 (API Breaking Changes)

(1) 问题

开发期间适逢 Mem0 官方发布 2.0.0 激进大版本，不仅引入了 Python 3.10+ 特有语法导致低版本系统瘫痪，更将其核心的 `search()` 返回结果从原先的列表结构暗中修改为了字典结构，引发 “string indices must be integers” 连锁崩溃。

(2) 解决

实施严格的版本锁定策略 (锁定至兼容性最强的 1.0.11)，并在业务层引入了鲁棒性极强的数据类型剥离校验：对返回的 `raw_memories` 进行 `isinstance(raw_memories, dict)` 探针检测，兼容不同版本的数据形态。

6 总结与体会

在金融财富管理场景中，安全的基石不仅仅在于预测市场的算法，更在于“倾听和理解客户”。记忆层技术的引入，补全了 LLM 从冰冷的“通用知识库”向温暖的“私人理财管家”进化的关键一环。

同时，本次项目的开发过程深刻印证了“纸上得来终觉浅”。从大模型的无缝对接，到多线程冲突的猴子补丁修复，再到向量维度的强行降阶对齐——真正的 AI 落地绝不只是一句 API 调用，而是要面对无数泥泞的底层架构坑。这些攻坚克难的工程经验，是本次博士课程人工智能实践课程项目中最为宝贵的财富。

参考文献

- [1] Chhikara P, Khant D, Aryan S, Singh T, et al. Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory [EB/OL]. arXiv:2504.19413, 2025.
<https://arxiv.org/abs/2504.19413>.
- [2] Packer C, Wooders S, Lin K, Fang V, Patil S G, Stoica I, Gonzalez J E. MemGPT: Towards LLMs as Operating Systems [EB/OL]. arXiv:2310.08560, 2023. <https://arxiv.org/abs/2310.08560>.
- [3] Lewis P, Perez E, Piktus A, Petroni F, Karpukhin V, Goyal N, Küttler H, Lewis M, Yih W, Rocktäschel T, Riedel S, Kiela D. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks [EB/OL]. arXiv:2005.11401, 2020. <https://arxiv.org/abs/2005.11401>.
- [4] GLM 团队 (智谱 AI, 清华大学). ChatGLM: A Family of Large Language Models from GLM-130B to GLM-4 All Tools [EB/OL]. arXiv:2406.12793, 2024.
<https://arxiv.org/abs/2406.12793>.
- [5] Qdrant Team. Qdrant Documentation: Vector Database for the Next Generation of AI Applications [EB/OL]. 2024. <https://qdrant.tech/documentation/>.
- [6] Gao Y, Xiong Y, Gao X, Jia K, Pan J, Bi Y, Dai Y, Sun J, Wang M, Wang H. Retrieval-Augmented Generation for Large Language Models: A Survey [J]. arXiv:2312.10997v5, 2024.
<https://arxiv.org/abs/2312.10997>.